

Einführung in die Neuroinformatik

Tim Luchterhand, Paul Nykiel (Gruppe P)

16. Mai 2018

1 Lernregeln

1.1

$$\begin{aligned}\frac{\partial E}{\partial w} &= \frac{\partial}{\partial w} \left(\frac{1}{2} \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b))^2 \right) \\ &= \sum_{\mu=1}^M \frac{1}{2} \cdot 2(T^\mu - f(w \cdot x^\mu + b)) \cdot (-f'(w \cdot x^\mu + b)) \cdot x^\mu \\ &= - \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b) \cdot x^\mu\end{aligned}$$

$$\begin{aligned}\frac{\partial E}{\partial b} &= \frac{\partial}{\partial b} \left(\frac{1}{2} \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b))^2 \right) \\ &= \sum_{\mu=1}^M \frac{1}{2} \cdot 2(T^\mu - f(w \cdot x^\mu + b)) \cdot (-f'(w \cdot x^\mu + b)) \\ &= - \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b)\end{aligned}$$

1.2

(a) Inkrementelle Version:

$$\begin{aligned}w(t+1) &= w(t) + \eta \cdot (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b) \cdot x^\mu \\ b(t+1) &= b(t) + \eta \cdot (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b)\end{aligned}$$

(b) Batch Version:

$$\begin{aligned}
 w(t+1) &= w(t) + \eta \cdot \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b) \cdot x^\mu \\
 b(t+1) &= b(t) + \eta \cdot \sum_{\mu=1}^M (T^\mu - f(w \cdot x^\mu + b)) \cdot f'(w \cdot x^\mu + b)
 \end{aligned}$$

1.3

(a) Ableitung der Transferfunktion:

$$f'(x) = -\frac{e^{-x}}{(1 + e^{-x})^2}$$

Werte des Gradienten berechnen:

$$\begin{aligned}
 \frac{\partial E}{\partial w}(-1, 3) &= -\sum_{\mu=1}^4 (T^\mu - f(-1 \cdot x^\mu + 3)) \cdot f'(-1 \cdot x^\mu + 3) \cdot x^\mu \\
 &= -((0 - f(4)) \cdot f'(4) \cdot -1) + 0 + ((0 - f(2)) \cdot f'(2) \cdot 1) + ((0 - f(1)) \cdot f'(1) \cdot 2) \\
 &= -(f(4)f'(4) - f(2)f'(2) - 2f(1)f'(1)) \\
 &= f(2)f'(2) + 2f(1)f'(1) - f(4)f'(4) \\
 &= -0.36 \\
 \frac{\partial E}{\partial b}(-1, 3) &= -\sum_{\mu=1}^4 (T^\mu - f(-1 \cdot x^\mu + 3)) \cdot f'(-1 \cdot x^\mu + 3) \\
 &= -((0 - f(4)) \cdot f'(4)) + 0 + ((0 - f(2)) \cdot f'(2)) + ((0 - f(1)) \cdot f'(1)) \\
 &= f(4)f'(4) + f(2)f'(2) + f(1)f'(1) \\
 &= -0.0041
 \end{aligned}$$

$$\Rightarrow \nabla E(w(0), b(0)) = \begin{pmatrix} -0.36 \\ -0.0041 \end{pmatrix}$$

(b)



Abbildung 1: Richtung des Gradienten

(c)

$$\begin{aligned}
 w(1) &= w(0) - \eta \cdot \frac{\partial E}{\partial w}(w(0), b(0)) \\
 &= -1 - 0.8 \cdot (-0.36) \\
 &= -0.712 \\
 b(1) &= b(0) - \eta \cdot \frac{\partial E}{\partial b}(w(0), b(0)) \\
 &= 3 - 0.8 \cdot (-0.0041) \\
 &= 3.0033
 \end{aligned}$$

(d) Der Gradientenabstieg findet nicht das globale Minimum sondern nur ein lokales Minimum, denn dort ist der Gradient aber ebenfalls $\vec{0}$.

1.4

- (a) Pfad 1 ist vermutlich durch die Batch-Lernregel entstanden, Pfad 2 durch die inkrementelle Lernregel.

Da bei der Batch-Lernregel der Gradient aus vielen Trainingssamples berechnet wird (also eine Art Durchschnitt), springt der Pfad weniger. Bei der inkrementellen Lernregel hingegen beeinflussen die einzelnen Trainingspaare den Pfad jeweils maßgeblich. Bei jeder Iteration wird nur genau ein Sample berücksichtigt, alle anderen Samples haben keinen Einfluss. Dadurch ist der Pfad deutlich weniger glatt, als bei der Batch-Lernregel.

- (b) Es ist möglich, dass beim inkrementellen Lernen kein globales Minimum gefunden wird, obwohl das Batch-Lernverfahren erfolgreich war. In dem Fall könnte das inkrementelle Lernen nur ein Minimum, welches für eine bestimmte Teilmenge der Trainingsamples gut passt, gefunden haben. Andererseits könnte das Batch-Lernverfahren nur ein lokales Minimum finden während das inkrementelle Lernverfahren „zufällig“ über dieses hinausspringt und noch weiter absteigen kann.

1.5

Bei zu großer Lernrate kann die Minimierung der Fehlerfunktion zu einer Art überschwingen oder sogar zu einer Oszillation führen. Da der Pfad immer zu weit „springt“ erreicht er somit nie das Minimum.

1.6

Es wird versucht die Übertragungsfunktion des Neurons so anzupassen, dass sie möglichst nah an allen Punkten ist. Die Funktion hat jedoch immer eine Sigmoid-Form und lässt sich durch das Training nur verschieben sowie strecken/stauchen. Da die Funktion aber streng monoton ist, kann sie so nie alle Punkte optimal annähern.